



AUDITORIA DE DADOS E ACCOUNTABILITY COM PYTHON
PESQUISA JURISPRUDENCIAL AUMENTADA NO SUPERIOR TRIBUNAL MILITAR: PROPOSTA DE INTEGRAÇÃO ENTRE RAG E GRAFOS PARA ANÁLISE DE ACÓRDÃOS SOBRE O CRIME DE DESERÇÃO

Docente: Prof. Dr. Aloísio Dourado Neto
Discente: Alexandre Hugo Santana Sampaio Netto
Matrícula: 1914824 | E-mail: xnetto2@hotmail.com
Superior Tribunal Militar — área judiciária

1 CONTEXTUALIZAÇÃO E DESCRIÇÃO DO PROBLEMA

A pesquisa jurisprudencial é atividade recorrente no apoio à prestação jurisdicional. No Superior Tribunal Militar (STM), o acervo público reúne acórdãos e metadados que registram a interpretação do Direito Penal e Processual Penal Militar. Questões complexas, porém, exigem localizar julgados materialmente próximos, reconstruir cadeias de precedentes e distinguir decisões com vocabulário semelhante em contextos fáticos diferentes.

O problema torna-se particularmente sensível nos julgamentos relativos ao crime de deserção e à alegação de estado de necessidade exculpante. A resposta jurídica pode depender da articulação entre fatos provados, requisitos da excludente, dispositivos do Código Penal Militar, súmulas e precedentes. A dispersão dessas relações em documentos extensos amplia o tempo de pesquisa e dificulta a visualização da evolução do entendimento, sobretudo quando a correspondência terminológica não traduz equivalência jurídica.

Propõe-se, por isso, uma arquitetura de pesquisa jurisprudencial que combine geração aumentada por recuperação (Retrieval Augmented Generation - RAG) e grafos de conhecimento. A pergunta orientadora é: como essa integração pode aprimorar a pesquisa, a rastreabilidade dos fundamentos e a identificação de relações jurisprudenciais em acórdãos do STM sobre deserção e estado de necessidade exculpante?

O objetivo geral é propor uma arquitetura capaz de recuperar, relacionar e sintetizar o conteúdo dos acórdãos com indicação verificável das fontes. Especificamente, pretende-se estruturar metadados e unidades argumentativas; combinar filtros, busca semântica e expansão por grafo; representar relações jurídicas; gerar respostas acompanhadas dos excertos de origem; e definir critérios de avaliação, governança e supervisão humana.

2 FUNDAMENTAÇÃO E TÉCNICAS SELECIONADAS



AUDITORIA DE DADOS E ACCOUNTABILITY COM PYTHON

O RAG associa um modelo generativo a um mecanismo externo de recuperação. A resposta é condicionada por documentos selecionados na consulta, favorecendo atualização, especialização e indicação das evidências utilizadas (LEWIS et al., 2020). No campo jurídico, a busca vetorial isolada pode recuperar trechos próximos sem revelar relações de citação, aplicação normativa, adoção de tese, distinção ou superação. Estudos empíricos mostram que o desenho do pipeline deve equilibrar qualidade e eficiência (WANG et al., 2024).

O grafo de conhecimento complementa essa limitação ao representar entidades e vínculos jurídicos. No modelo proposto, Acórdão, Tema, Tese, Norma, Súmula e Precedente constituem nós; TRATA_DE, APLICA, CITA, ADOTA_TESE, DISTINGUE, DIVERGE_DE e SUPERA constituem relações. A integração permite partir de um fragmento semanticamente relevante e percorrer conexões que uma busca puramente lexical ou vetorial não evidencia. Abordagens GraphRAG demonstram a utilidade de estruturas relacionais para organizar corpus extensos e apoiar respostas que demandem visão global (EDGE et al., 2024). LLMs e grafos são complementares na representação e na consulta de conhecimento estruturado (PAN et al., 2024), inclusive em recuperação multi-hop apoiada por PageRank (GUTIÉRREZ et al., 2024).

A proposição central é que a recuperação semântica combinada à navegação por relações jurídicas tende a oferecer maior rastreabilidade e cobertura de precedentes do que a pesquisa lexical ou o RAG vetorial isolado, desde que as respostas permaneçam vinculadas às fontes e à conferência humana. Não se pressupõe aumento de correção decisória.

3 METODOLOGIA PROPOSTA E DADOS

O *corpus* piloto abrangerá acórdãos públicos do STM publicados entre 01.01.2021 e 31.12.2025 e associados à deserção e ao estado de necessidade exculpante. Precedentes anteriores citados nesses documentos poderão ser incorporados para preservar a cadeia jurisprudencial. As fontes previstas são a Consulta Judicial Unificada e o repositório institucional de Acórdãos e enunciados de Súmula. Serão coletados apenas documentos oficialmente disponibilizados, com seus metadados de origem, sem reidentificação ou enriquecimento desnecessário de dados pessoais.

A ingestão será realizada em Python, com PyMuPDF ou pdfplumber para extração dos PDFs e pandas para normalização dos metadados. O processo verificará falhas de OCR, páginas ausentes, duplicidades e correspondência com o registro oficial. Extrações insuficientes serão sinalizadas para correção ou exclusão justificada.



AUDITORIA DE DADOS E ACCOUNTABILITY COM PYTHON

3.1 Segmentação, indexação e representação do conhecimento

A segmentação será hierárquica e orientada pela estrutura jurídica. Ementa e dispositivo serão preservados integralmente; relatório e voto serão divididos por unidades temáticas. Como os fundamentos nem sempre têm título próprio, serão identificados dentro do voto. Um limite de tokens e pequena sobreposição entre blocos atuarão como proteções técnicas, sem substituir a coerência semântica.

Cada chunk conservará número do processo, classe, assunto, relator, data, seção, página e ligação com o acórdão integral. Essa proveniência evita que fatos do relatório sejam confundidos com fundamentos ou que o dispositivo seja apresentado como argumento. Os embeddings serão armazenados em ChromaDB ou FAISS. Filtros estruturados reduzirão o espaço de busca por período, classe, assunto e dispositivo antes da recuperação vetorial.

A extração do grafo adotará método híbrido. Regras localizarão processos, artigos, súmulas e citações; metadados oficiais fornecerão classes e assuntos; um modelo de linguagem poderá sugerir questões, teses e fundamentos. NetworkX atenderá ao protótipo, e Neo4j à futura escalabilidade. Toda relação inferida armazenará origem, fragmento comprobatório, método, confiança e estado de conferência.

Acórdãos públicos	Extração e segmentação	Embeddings e entidades	Base vetorial + grafo	Recuperação híbrida	Resposta citada + mapa
-------------------	------------------------	------------------------	-----------------------	---------------------	------------------------

Figura 1 — Fluxo conceitual da solução proposta

3.2 Recuperação híbrida e geração da resposta

A consulta será processada em seis etapas: aplicação de filtros; recuperação dos chunks semanticamente próximos; expansão para normas, precedentes, súmulas e teses conectadas; reordenação por relevância; geração condicionada às evidências; e apresentação conjunta da resposta, dos excertos, dos documentos e do caminho percorrido no grafo. A ferramenta deverá declarar insuficiência de evidências quando o corpus não sustentar uma conclusão. A expansão de chunks semânticos pelo grafo segue estratégia avaliada no KG2RAG (ZHU et al., 2025).

Uma possível divergência material será apenas sinalizada, nunca afirmada autonomamente. O sistema exibirá trechos, fundamentos, resultados e distinções identificadas, deixando a qualificação jurídica ao usuário. Também não classificará magistrados, avaliará desempenho decisório nem formará perfis de partes ou profissionais.

3.3 Avaliação, segurança e governança

Consultas elaboradas pelo autor servirão a testes preliminares, com conferência manual das respostas e fontes. Serão comparadas pesquisa lexical, RAG vetorial e RAG-grafo. Precision@k e Recall@k avaliarão relevância e cobertura; correção das citações, fidelidade, elementos esperados e tempo



AUDITORIA DE DADOS E ACCOUNTABILITY COM PYTHON

complementarão a análise. A inexistência de avaliação independente será explicitada, e nenhuma métrica será apresentada antes de calculada.

Embora os acórdãos sejam públicos, o protótipo utiliza uma base de trabalho anonimizada antes da segmentação e da indexação. O processamento substitui identificadores pessoais e nomes associados a papéis privados, preserva os agentes públicos necessários à compreensão do julgado e produz relatórios para conferência humana. A anonimização é adotada como controle de redução da exposição, sem ser tratada como garantia absoluta contra reidentificação. Essa medida concretiza os princípios da finalidade, adequação, necessidade, segurança, prevenção e prestação de contas previstos na Lei Geral de Proteção de Dados Pessoais. Os arquivos oficiais permanecem separados da base de consulta, com proveniência, hashes, versionamento, retenção definida e procedimento de correção, enquanto atributos pessoais sem utilidade jurídica são excluídos do índice.

A supervisão humana é requisito funcional: a resposta não servirá como decisão automática e inferências sem fonte não serão exibidas como fatos. Para mitigar prompt injection, o conteúdo recuperado será tratado como dado, não como instrução. Controle de acesso e versionamento do *corpus* e dos parâmetros apoiarão a auditoria.

4 RESULTADOS ESPERADOS E IMPACTO

Produziu-se uma interface de pesquisa capaz de responder a questões sobre deserção com citações verificáveis, mapa de precedentes e linha do tempo da evolução jurisprudencial. O principal benefício institucional esperado é reduzir o tempo necessário à pesquisa sem sacrificar a rastreabilidade dos fundamentos. Como efeitos complementares, projetam-se maior cobertura de julgados relacionados, visualização de cadeias de citação e identificação assistida de distinções ou possíveis divergências.

A proposta não substitui a consulta ao inteiro teor nem a interpretação jurídica. Entre as limitações estão erros de OCR; variações documentais; dificuldade de distinguir fundamento determinante de argumento acessório; perda de contexto no chunking; omissões; alucinações; citações incorretas; falsos alertas de divergência; dependência dos metadados; e atualização contínua.

A viabilidade decorre do acervo público, de bibliotecas consolidadas e da implantação incremental: ingestão e busca semântica; extração do grafo; recuperação híbrida e testes comparativos. O fracionamento reduz o risco e permite corrigir falhas antes da ampliação para outras matérias.

5 CONSIDERAÇÕES FINAIS



AUDITORIA DE DADOS E ACCOUNTABILITY COM PYTHON

O trabalho delineou uma aplicação de RAG e grafos à pesquisa de acórdãos públicos do STM sobre deserção e estado de necessidade exculpante. Sua contribuição é integrar recuperação de trechos e relações jurídicas com proveniência verificável, superando a dificuldade das buscas lexicais e do RAG vetorial isolado para reconstruir conexões entre julgados, teses, normas, súmulas e precedentes.

A segmentação jurídica, a extração híbrida, a expansão pelo grafo e os excertos comprobatórios conferem auditabilidade ao fluxo. Como similaridade textual não equivale a identidade jurídica e divergências dependem dos fatos e fundamentos, a ferramenta limita-se ao apoio à pesquisa, sem automatizar conclusões ou avaliar decisões e seus autores.

Como próximos passos, propõe-se implementar o piloto de 2021 a 2025, executar testes do autor e comparar pesquisa lexical, RAG vetorial e RAG-grafo. A expansão para outras matérias dependerá de maior segmentação da base de dados, visando a normalização para proveniência e atualização, fazendo da escalabilidade consequência do controle de qualidade.

REFERÊNCIAS

- BRASIL. Conselho Nacional de Justiça. Resolução n. 615, de 11 de março de 2025. Estabelece diretrizes para o desenvolvimento, utilização e governança de soluções desenvolvidas com recursos de inteligência artificial no Poder Judiciário. Brasília, DF: CNJ, 2025. Disponível em: <https://atos.cnj.jus.br/atos/detalhar/6001>. Acesso em: 25 ago. 2026.
- BRASIL. Lei n. 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF: Presidência da República, 2018. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/113709.htm. Acesso em: 25 ago. 2026.
- BRASIL. Superior Tribunal Militar. Acórdãos e súmulas. Brasília, DF: STM, [s. d.]. Disponível em: <https://dspace.stm.jus.br/handle/123456789/200>. Acesso em: 25 ago. 2026.
- BRASIL. Superior Tribunal Militar. Consulta Judicial Unificada: jurisprudência. Brasília, DF: STM, [s. d.]. Disponível em: <https://jurisprudencia.stm.jus.br/>. Acesso em: 25 ago. 2026.
- EDGE, Darren et al. From local to global: a graph RAG approach to query-focused summarization. arXiv, 2024. DOI: 10.48550/arXiv.2404.16130.
- GUTIÉRREZ, Bernal et al. HippoRAG: neurobiologically inspired long-term memory for large language models. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 37., 2024. Proceedings [...]. [S. l.]: NeurIPS, 2024. p. 59532-59569. DOI: 10.52202/079017-1902.
- LEWIS, Patrick et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 33., 2020. Proceedings [...]. [S. l.]: NeurIPS, 2020. p. 9459-9474.
- MANNING, Christopher D.; RAGHAVAN, Prabhakar; SCHÜTZE, Hinrich. Introduction to information retrieval. Cambridge: Cambridge University Press, 2008.
- PAN, Shirui et al. Unifying large language models and knowledge graphs: a roadmap. IEEE Transactions on Knowledge and Data Engineering, v. 36, n. 7, p. 3580-3599, 2024. DOI: 10.1109/TKDE.2024.3352100.
- WANG, Xiaohua et al. Searching for best practices in retrieval-augmented generation. In: PROCEEDINGS OF THE 2024 CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING. Miami: Association for Computational Linguistics, 2024. p. 17716-17736. DOI: 10.18653/v1/2024.emnlp-main.981.
- ZHU, Xiangrong et al. Knowledge graph-guided retrieval augmented generation. In: PROCEEDINGS OF THE 2025 CONFERENCE OF THE NATIONS OF THE AMERICAS CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS: HUMAN LANGUAGE TECHNOLOGIES. Albuquerque: Association for Computational Linguistics, 2025. p. 8912-8924. DOI: 10.18653/v1/2025.naacl-long.449.